## Általános információk, a diplomaterv szerkezete

A diplomaterv szerkezete a BME Villamosmérnöki és Informatikai Karán:

- 1. Diplomaterv feladatkiírás
- 2. Címoldal
- 3. Tartalomjegyzék
- 4. A diplomatervező nyilatkozata az önálló munkáról és az elektronikus adatok kezeléséről
- 5. Tartalmi összefoglaló magyarul és angolul
- Bevezetés: a feladat értelmezése, a tervezés célja, a feladat indokoltsága, a diplomaterv felépítésének rövid összefoglalása
- 7. A feladatkiírás pontosítása és részletes elemzése
- 8. Előzmények (irodalomkutatás, hasonló alkotások), az ezekből levonható következtetések
- A tervezés részletes leírása, a döntési lehetőségek értékelése és a választott megoldások indoklása
- 10. A megtervezett műszaki alkotás értékelése, kritikai elemzése, továbbfejlesztési lehetőségek
- 11. Esetleges köszönetnyilvánítások
- 12. Részletes és pontos irodalomjegyzék
- 13. Függelék(ek)

Felhasználható a következő oldaltól kezdődő IATFXdiplomatervsablon dokumentum tartalma.

A diplomaterv szabványos méretű A4-es lapokra kerüljön. Az oldalak tükörmargóval készüljenek (mindenhol 2,5 cm, baloldalon 1 cm-es kötéssel). Az alapértelmezett betűkészlet a 12 pontos Times New Roman, másfeles sorközzel, de ettől kismértékben el lehet térni, ill. más betűtípus használata is megengedett.

Minden oldalon – az első négy szerkezeti elem kivételével – szerepelnie kell az oldalszámnak.

A fejezeteket decimális beosztással kell ellátni. Az ábrákat a megfelelő helyre be kell illeszteni, fejezetenként decimális számmal és kifejező címmel kell ellátni. A fejezeteket decimális aláosztással számozzuk, maximálisan 3 aláosztás mélységben (pl. 2.3.4.1.). Az ábrákat, táblázatokat és képleteket célszerű fejezetenként külön számozni (pl. 2.4. ábra, 4.2. táblázat vagy képletnél (3.2)). A fejezetcímeket igazítsuk balra, a normál szövegnél viszont használjunk sorkiegyenlítést. Az ábrákat, táblázatokat és a hozzájuk tartozó címet igazítsuk középre. A cím a jelölt rész alatt helyezkedjen el.

A képeket lehetőleg rajzoló programmal készítsék el, az egyenleteket egyenlet-szerkesztő segítségével írják le (A IAT<sub>E</sub>X ehhez kézenfekvő megoldásokat nyújt).

Az irodalomjegyzék szövegközi hivatkozása történhet sorszámozva (ez a preferált megoldás) vagy a Harvard-rendszerben (a szerző és az évszám megadásával). A teljes lista névsor szerinti sorrendben a szöveg végén szerepeljen (sorszámozott irodalmi hivatkozások esetén hivatkozási sorrendben). A szakirodalmi források címeit azonban mindig az eredeti nyelven kell megadni, esetleg zárójelben a fordítással. A listában szereplő valamennyi publikációra hivatkozni kell a szövegben (a LATEX-sablon a BibTEX segítségével mindezt automatikusan kezeli). Minden publikáció a szerzők után a következő adatok szerepelnek: folyóirat cikkeknél a pontos cím, a folyóirat címe, évfolyam, szám, oldalszám tól-ig. A folyóiratok címét csak akkor rövidítsük, ha azok nagyon közismertek vagy nagyon hosszúak. Internetes hivatkozások megadásakor fontos, hogy az elérési út előtt megadjuk az oldal tulajdonosát és tartalmát (mivel a link egy idő után akár elérhetetlenné is válhat), valamint az elérés időpontját.

#### Fontos:

- A szakdolgozatkészítő / diplomatervező nyilatkozata (a jelen sablonban szereplő szövegtartalommal) kötelező előírás, Karunkon ennek hiányában a szakdolgozat/diplomaterv nem bírálható és nem védhető!
- Mind a dolgozat, mind a melléklet maximálisan 15 MB méretű lehet!

Jó munkát, sikeres szakdolgozatkészítést, ill. diplomatervezést kívánunk!

## FELADATKIÍRÁS

A feladatkiírást a tanszéki adminisztrációban lehet átvenni, és a leadott munkába eredeti, tanszéki pecséttel ellátott és a tanszékvezető által aláírt lapot kell belefűzni (ezen oldal *helyett*, ez az oldal csak útmutatás). Az elektronikusan feltöltött dolgozatban már nem kell beleszerkeszteni ezt a feladatkiírást.



#### Budapesti Műszaki és Gazdaságtudományi Egyetem

Villamosmérnöki és Informatikai Kar Távközlési és Médiainformatikai Tanszék

# Mély neuronháló alapú orosz nyelvű beszédfelismerő fejlesztése

SZAKDOLGOZAT

 $\it K\acute{e}sz\acute{i}tette$  Dobsinszki Gergely

Konzulens dr. Mihajlik Péter

# Tartalomjegyzék

Ki	Kivonat								
Al	ostra	$\operatorname{ct}$	ii						
1.	Bevezetés								
	1.1.	Gépi beszédfelismerés	1						
	1.2.	Út az end to end alapú gépi beszédfelismerésig	2						
	1.3.	Az orosz nyelv	2						
	1.4.	Megoldások	3						
	1.5.	Összefoglaló	4						
	1.6.	Diplomaterv felépítése	5						
2.	Fela	ndatkiírás részletes elemzése	6						
	2.1.	Beszédfelimserés bemutatása	6						
	2.2.	Korszerű architektúrák és tervezés	6						
	2.3.	Orosz nyelvű implementáció	7						
	2.4.	Optimaliziálás és kiértékelés	8						
	2.5.	Munka összegzése és kitekintés	8						
3. Elméleti összefoglaló									
	3.1.	Hagyományostól az end-to-end-ig	9						
	3.2.	A beszédfelimserés lépései	10						
		3.2.1. Előfeldolgozás	10						
		3.2.2. Neurális hálók	11						
		3 2 3 CTC loss számítás	1/1						

4.	Tervezés							
5.	Össz	Összefoglalás						
6.	I⁴T <sub>E</sub> X-eszközök							
	6.1.	A szerkesztéshez használatos eszközök	17					
	6.2.	A dokumentum lefordítása Windows alatt	17					
	6.3.	Eszközök Linuxhoz	19					
7.	A dolgozat formai kivitele							
	7.1.	A dolgozat kimérete	21					
	7.2.	A dolgozat nyelve	21					
	7.3.	A dokumentum nyomdatechnikai kivitele	22					
8.	A I&TEX-sablon használata							
	8.1.	Címkék és hivatkozások	23					
	8.2.	Ábrák és táblázatok	24					
	8.3.	Felsorolások és listák	26					
	8.4.	Képletek	27					
	8.5.	Irodalmi hivatkozások	29					
	8.6.	A dolgozat szerkezete és a forrásfájlok	33					
	8.7.	Alapadatok megadása	35					
	8.8.	Új fejezet írása	35					
	8.9.	Definíciók, tételek, példák	35					
Κċ	iszön	etnyilvánítás	36					
Függelék								
	F.1.	A TeXstudio felülete	37					
	F.2.	Válasz az "Élet, a világmindenség, meg minden" kérdésére	38					
Iro	odalo	mjegyzék	37					

HALLGATÓI NYILATKOZAT

Alulírott Dobsinszki Gergely, szigorló hallgató kijelentem, hogy ezt a szakdolgo-

zatot meg nem engedett segítség nélkül, saját magam készítettem, csak a megadott

forrásokat (szakirodalom, eszközök stb.) használtam fel. Minden olyan részt, me-

lyet szó szerint, vagy azonos értelemben, de átfogalmazva más forrásból átvettem,

egyértelműen, a forrás megadásával megjelöltem.

Hozzájárulok, hogy a jelen munkám alapadatait (szerző(k), cím, angol és ma-

gyar nyelvű tartalmi kivonat, készítés éve, konzulens(ek) neve) a BME VIK nyilvá-

nosan hozzáférhető elektronikus formában, a munka teljes szövegét pedig az egyetem

belső hálózatán keresztül (vagy autentikált felhasználók számára) közzétegye. Kije-

lentem, hogy a benyújtott munka és annak elektronikus verziója megegyezik. Dékáni

engedéllyel titkosított diplomatervek esetén a dolgozat szövege csak 3 év eltelte után

válik hozzáférhetővé.

Budapest, 2020. november 9.

Dobsinszki Gergely

hallgató

# **Kivonat**

Jelen dokumentum egy diplomaterv sablon, amely formai keretet ad a BME Villamosmérnöki és Informatikai Karán végző hallgatók által elkészítendő szakdolgozatnak és diplomatervnek. A sablon használata opcionális. Ez a sablon IATEX alapú, a TeXLive TeX-implementációval és a PDF-IATEX fordítóval működőképes.

# Abstract

This document is a LaTeX-based skeleton for BSc/MSc theses of students at the Electrical Engineering and Informatics Faculty, Budapest University of Technology and Economics. The usage of this skeleton is optional. It has been tested with the TeXLive TeX implementation, and it requires the PDF-LaTeX compiler.

## Bevezetés

### 1.1. Gépi beszédfelismerés

Az automatikus gépi beszédfelismerés régóta foglalkoztatja az emberek fantáziáját. Személyi asszisztens formájában már évtizedekkel ezelőtt találkozhatott vele bármilyen sci-fi kedvelő. De napjainkban már ott lapul a zsebünkben is a technológia, az okostelefonjaink, melyek a legtöbb ember számára a mindennapok részét képzik, rendelkeznek beszédfelismerő funkcióval. Legyen az egy személyi asszisztens, amely segítségével például könnyedén beállíthatóak emlékeztetők, vagy egy egyszerű Google Search-ön alapuló keresés, melyhez a begépelést hang segítségével is el lehet végezni. Nappalinkban is egyre inkább hódít, jó példa rá az Amazon Alexa-ja, aminek a segítségével több okos eszköz is kezelhető a lakóterünkben.

Ezek a technológiák mind automatikus beszédfelismerésen alapszanak, amelyet alkalmazva az ember kizárólag hang interfész segítségével tud kommunikálni a géppel, mintha csak egy másik emberrel csevegne. Ez a megközelítés nagy szabadságot nyújt a kommunikáló számára, nem köti többé billentyűzet, egér, érintőképernyő de még monitor, kijelző sem. Egyre inkább pontosodó, esetenként még az emberi prezicitáson is túlmutató, felismerés nyújtotta lehetőségek felhasználási területe egyre bővül, egyre inkább bekerül a köztudatba és mindennapjainkba.

## 1.2. Út az end to end alapú gépi beszédfelismerésig

A fonográf, egy Thomas Eddison által jegyzett 1877-es találmány, volt az első eszköz mely hang rögzítésére alkalmas volt. A módszer finomításával és térhódításával, illetve a számítógépek megjelenésével, és a digitalizácóval megjele. Az első komoly eredményeket felmutató kutatási projektett a beszédfelismerés területén az Egyesült Államokbeli Fejlett Védelmi Kutatási Projektek Ügynöksége (DARPA) finanszírózta. A kutatás célja egy 1000 szavat felismerni képes program megalkotása volt, melyet a kitűzött 5 éven belül sikerült is megalkotni https://en.wikipedia.org/wiki/Timeline\_of\_speech\_and\_voice\_recognition.

Az 1980-as években egy újabb technológia a rejtett Markov modell forradalmasította a gépi beszédfelismerést. Segítségével pontosítható volt az ismeretlen hangok szóként való felismerésének a valószínűsége. A modell napjainkban is nagy sikerességnek örvend, rendkívül elterjedten használják különböző elemekkel, akkusztikusés nyelv modellekkel, párosítva a lehető legpercízebb beszédfelismerés végett.

A neurális hálók térhóditásával 2010-es években megjelent egy alternatív, folyamatosan terjedő megközelítés az end-to-end alapú beszédfelismerés. Segítségével kiküszöbölhető a komplex, több elemből álló módszerek alkalmazása, és egy egységből felépülő modell állítható elő.

### 1.3. Az orosz nyelv

Ahogy az a 1.1-es ábrán látható világszerte az egyik legelterjedtebb nyelv az angol, mely nem csak a közösségi, társadalmi és politikai, hanem a tudományos életet is uralja. Nem meglepő, hogy ezt a nyelvet tekintjük a beszédfelismerő rendszerek pontosággának mérésekor alapnak, ezen a nyelven vannak a legkiterjettebb szabadon elérhető beszéd adatbázisok is.

Számos nyelvet beszélnek világszerte az angol mellett, sokak számára viszont az angol nem az anyanyelvük, estleg egyáltalán nem beszélik azt. Beszédfelismerés során tehát szükséges egyéb hivatalos nyelveket is vizsgálni és kutatni.

Oroszország politikai és kulturális befolyása a világ ügyeibe vitathatatlan, így az orosz nyelv is fontos szerepet tölt be a nemzetközi porondon. Az 1.1-es ábrán látható,





**1.1. ábra.** Országok száma, melyekben az adott nyelvet beszélik.

hogy elterejedt nyelvnek számít több országban is. Az end-to-end technológia és a neurális hálók által nyújtott lehetőségek megkönnyítik a nyelvek közti átállást, így egy angoltól eltérő nyelv vizsgálata és kutatása gördülékenyen megvalósítható egy angol nyelvű példa alapján.

## 1.4. Megoldások

A beszédfelismerő rendszereket pontosságuk alapján tudjuk rangsorolni. Egy nemzetközileg elismert pontossági mérőszám a WER (Word Error Rate). Ezt a pontosságot szokás szerint egy publikusan elérhető, angol nyelvű hangoskönyv felolvasásokat tartalamzó adatbázison, a LibriSpeech-en¹ mérik.

<sup>&</sup>lt;sup>1</sup>LibriSpeech oldala: http://www.openslr.org/12/

Különböző, alacsony hibaarányú modellek léteznek, de ez egyik lekiemelkedőbb közülök az Nvidia QuartzNet<sup>2</sup> modelje, mely alacsonyszámú paraméterek mellett képes igen nagy preciziót fenntartani. Míg a QuartzNet bonyolultsága, paramétereinek a száma csupán töredéke a legtöbb SOTA modellének, a WER száma megközelíti azokét (1.1-es táblázat).

A modellekben elterjedt a konvolúciós- (CNN) és rekurrens neurális rétegek (RNN) használata.

Model	Aug	LM	$\frac{\text{clean}}{\text{WER}(\%)}$	$\frac{\text{other}}{\text{WER}(\%)}$	Million Parame- ters
wav2letter++	Speed Perturb	ConvLM	3.26	10.47	208
LAS	SpecAugment	RNN	2.5	5.8	360
Time-Depth Separable Convolu- tions	Dropout, Label Smoothing	N/A (greedy)	5.36	15.64	37
		4-gram	4.21	11.87	
		ConvLM	3.28	9.84	
Multi- Stream Self- Attention	Speed Perturb	4-gram	2.93	8.32	23
		4-LSTM	2.20	5.82	
QuartzNet- 15x5	Spec Cutout, Speed Perturb	N/A (greedy)	3.90	11.28	19
		6-gram	2.96	8.07	
		Transformer-XL	2.69	7.25	

1.1. táblázat. Angol nyelven tanult SOTA beszédfelismerő modellek és paramétereik.

## 1.5. Összefoglaló

Megoldásomban az Nvidia QuartzNet alapján indultam el, annak alacsony paraméterszámát figyelembe véve. Egy Pytorch alapú toolkit-et, az Nvidia NeMo-t (Neural Modules) használva kísérleteztem QuartzNet kombinációkkal.

Főként az ingyenesen hozzáférhető Mozilla Common Voice adatbázist haszálva tanítottam orosz nyelvre a legsikeresebbnek ítélt, 15x5 architektúrájú modellt. A modellt nem véletlenszerűen beállított súlyokkal, hanem transfer learning-et alkalmazva, egy előre tanított angol modellbeli súlyokkal inicilaizáltam.

 $<sup>^2\</sup>mathrm{Az}$  Nvidia ismertető oldala: https://developer.nvidia.com/blog/develop-smaller-speech-recognition-models-with-nvidias-nemo-framework/

Az eredmény finomítása végett próbálkoztam több tanítóadat beiktatásával, mellyel a validációs adathalmaz WER értéke csökkent, így javult. Sajnos a több tanítóadat lényeges megnövelte a tanítás idejét így erőforrások szűkében csökkentette a kísérletezésre jutó időt, ezért ezt a módszert csak kis mértékben alkalmaztam.

#### 1.6. Diplomatery felépítése

A feladatkiírás elemzése fejezetben a sarkalatos pontok kerülnek részletezésre, kifejtésre. Ezen pontok kidolgozásának lehetőségei, esetleges nehézségei kerülnek említésre a felsorakoztatva a tervezés előtt felmerült, megvalósított és elvetett ötleteket.

Az előzmények és irodalomkutatás rész az eddigi megoldásokat részletezi és veti össze, röviden értékelve azok sikerességét. A levonható következtetések fényében felsorakoztat néhány későbbi tervezésbeli döntést.

A tervezés fejeztet magába foglalja az előzetes döntéseket, a lehetséges kísérletek várható eredményét, a döntési lehetőségeket értékelve és az azok mögötti ötleteket, esetleges alternatívákkal kiegészítve. A végső soron válaszott megoldások alátámasztása és indoklása is megjelenik a részben.

Az összefoglaló tartalmazza az elért eredmények bemutatását, azok értékelését és a végső következtetések levonását.

## Feladatkiírás részletes elemzése

#### 2.1. Beszédfelimserés bemutatása

Az irodalomkutatás során az end-to-end alapú beszédfelismerést különböző források, cikkek, internetes bologok és papírok alapján célszerű végezni. Mivel egy egészen új és feltörekvő megközelítésről van szó, célszerű a forrásokat megvizsgálni, összevetni az azonos témáról írtakat az alátámasztás és a könnyebb értelmezhetőség végett.

A neurális hálók prezentálása elengedhetelen, lényegretörő bemutatásuk és szerepük nyomán a beszédfelimserésben. Fontos kitérni az end-to-end alap mivoltára, ennek előnyeinek és hátrányainak bemutatása az eddig bevált, hagyományos mód-szerekkel szemben.

Érdemes az elméleten túl a potenciálisan felhasználható megoldásokat részletesen megismerni, melyek implementálhatók a későbbi tervezés során a jobb eredmények végett.

#### 2.2. Korszerű architektúrák és tervezés

Többféle neuronhálós architketúrák léteznek különböző feladatokra, így a beszédfelismerésre is. Felderítésük, előnyeik és hátrányaik megismerése és összevetésük az irodalomkutatás nyomán végezhető el.

A neurális hálók természetüknél fogva igen összetettek, ezért gyakori az egyes rendszerek magas erőforrásigénye, melyeket a diplomamunka keretein belül akár kivitelezhetetlen is lenne használni. Ezért célszerű, hogy olyan architektúrát válasszunk, ami az előzőek alapján optimális teljesítményt nyújt, azaz látványos és felhasználható eredmények elérésére képes a lehető legrövidebb idő alatt a legkevesebb erőforrást felhasználva. Az idő rövidsége a tesztelési fázist is nagyban felgyorsíthatja, így szerepe kulcsfontosságú, míg természetesen fontos és nem elhanyagolható a pontosság is.

Kezdetben angol nyelven célszerű tesztelni az megtervezett architektúrát és az egyes paramétereinek pontosítását, mivel angol nyelven rengeteg eredmény elérhető, ezáltal összevethető. Ha egy megtervezett rendszer működésének megítélése angol nyelvű adatok alapján megfelelő akkor már célszerű áttérni az orosz nyelvre.

### 2.3. Orosz nyelvű implementáció

Egy angoltól eltérő nyelvre való áttéréskor el kell végezni annak a vizsgálatát, hogy az újabb nyelv milyen különbségeket rejt. Egy gyakori eltérés az ABCi, de előfordulhatnák más előfeldolgozásbeli különbségek is. Ha egy keretrendszer angol nyelvre van optimalizálva, előfordulhat, hogy ezeket a finomításokat el kell vetni és egy általános megközelítést kell alkalmazni az új nyelv tanítása során.

A célnyelvi adatokat különböző forrásokból lehet begyűjetni. Mivel az adatbázisok csak nyíltak lehetnek, ezért ezek megbízhatóságát meg kell vizsgálni akár szúrópróbaszerűen akár más felhasználók véleménye alapján. Az adatok mérete mind a neurális modellek tanítási ideje mind tárhelykapacitás miatt nem szabad, hogy túl nagy legyen, meg kell találni az optimális mennyiséget.

Tanítás során a jobb eredmény elérése érdekében alkalmazható a transferlearning, ami egy elterjedt tanítási módszer neurális hálók használata során. Ez a folyamat egy adott architektúrájú, előre tanított modell továbbtanítását foglalja magába. Beszédfelismerés esetén az eredeti modelltől eltérő nyelv alkalmazásánál kihívást jelent a nyelvre való áttérés. Szerencsére lehetőség van az előre tanított modell tetszőleges részeit átvenni, nem szükséges a nyelvspecifikus elmeket is importálni, így azok tanításhoz kezdődhet nulláról.

Célszerű az architektúra tervezésénél gondolni a szabadon elérhető előre tanított modellekre és ilyen felépítéseket is fontolóra venni és megvizsgálni, hiszen csak ezekkel lehetséges a transfer-learning alkalmazása.

#### 2.4. Optimaliziálás és kiértékelés

Az elkészült modellt ki kell értékelni, összehasonlítani más eredményekkel és vélemenyezni az így elért eredményt. A kiérétkeléshez egy elterjdet módszert kell ezért használni, hogy összemérhetőek elgyenek az eredmények.

Lehetőség van az eredmény javítására különböző módszerekkel, melyek már ismertek a neurális hálók körében, vagy főként beszédfelismerésnél jelennek meg. Az előbbi csoportba tartozik például az augmentálás, mely folyamat során a meglévő tanítóhalmazt dúsítják különböző módszerekkel. Utóbbi csoportba tartoznak a különböző dekóderek, annak a módja hogy hogyan értelmezzük a valószínűségként kapott kimeneteket az egyes időpillanatokban, illetve a nyelv modellek.

## 2.5. Munka összegzése és kitekintés

Befejezeséképp kerül sor a kitűzött fealdatok sikerességének bemutatására, az elért eredmények részletezéséve és az esetleges kudarcok a zsákutcák leírására.

További, ki nem próbált lehetőséget és fejlesztési ötletek javaslását is elvégezzük, indokolva, hogy miért is jelenthetnek fejlődést az eredményekben és hogy ezek miért nem lettek megvalósítva, kipróbálva.

# Elméleti összefoglaló

## 3.1. Hagyományostól az end-to-end-ig

A hagyományos ASR-ok (automatikus beszédfelismerők) több elemből álló, összetett rendszerek, melyek manapság igen pontosan meg tudják állapítani mi volt az eredetileg elhangzott szöveg, és leképezik azt írásos formába. Az egyik legelterjettebb a HMM (Rejtett Markov Modell) alapú beszédfelismerő rendszer [1]. A rendszernek több eleme is van: egy dekóder mely tartalmaz egy nyelv modellt, akusztikus modelleket és egy kiejtési szótárat is, illetve tartalmaz egy elemet, mely a bemeneti hangból a kiemeli jellemzőket, átalakítja őket a rendszer által kezelhető formájúvá. A HMM-en alapuló rendszerek fő eleme a Viterbi algoritmus, mely dinamikus programozást alkalmazva találja meg a legjobb illeszkedést a bemeneti szöveg és az adott beszéd modell közt.

A rendszer különböző elemeo erősen függenek egymástól. Ha az egyik nem rendeltetés szerűén működik és rossz kimenetet ad, akár saját vagy egy korábbi elem hibájából kifolyólag az befolyásolja a többi elemet is, így elrontva, torzítva a kapott végeredményt. Az egyes elemeket külön-külön kell kalibrálni, tanítani és tökéletesíteni.

Ezzel szemben, a napjainkban egyre inkább népszerű, E2E (end-to-end) alapú beszédfelismerő rendszerek [2] sokkal egyszerűbb, kevesebb köztes elemet igénylő megközelítést nyújtanak. Bizonyos szituációkban, ahol egy specifikusabb szövegkörnyezetben, pl. pénzügyi vagy jogi, elhangzó szavak azonosítása a cél, már a hagyományos ASR rendszereknél is pontosabb eredményeket képesek produkálni.

Az E2E rendszerek mély neurális hálókon alapszanak, közvetlen bemenetök a nyers hang, kimenetük pedig a becsült szöveg. Természetesen a neurális háló bemenetéhez a hangot még előre fel kell dolgozni, amit pre-processing-nek neveznek. A háló kimenete pedig az egyes bemeneti időegységekre becsült karakterek valószínűségei melyekből ki kell nyerni a végső, feltételezett szöveget.

### 3.2. A beszédfelimserés lépései

#### 3.2.1. Előfeldolgozás


A beszéd előfeldolgozása az első fontos lépése a beszédfelismerő rendszereknek. Vannak törekvések, melyekben a E2E neurális hálónak közvetlenül a nyers, feldolgozatlan hanganyagot adják meg és ez alapján tanítják [4], ezáltal még inkább tisztán a neurális háló működésére támaszkodva. Egyelőre ennek a megközelítésnek az eredményei messze elmaradnak a hang előfeldolgozásával elérhető SOTA modellek pontosságától.

A két fő megközelítés többnyire hasonló, apró eltérésekkel. Az egyik legelterjedtebb és bevált átalakítás a spektogram.

Ahogy az 1. ábrán is látható, a spektogramm három tengely mentén reprezentálja az adatot. Az x tengelyen az idő, míg az y tengelyen a frekvencia van megadva. Van továbbá egy harmadik tengely is, ami színnel van jelölve és mértékegysége a decibel. Ez a jel amplitúdója vagy energiája. Világosabb szín erősebb, hangosabb hangot, illetve sötétebb szín gyengébb, alacsonyabb hangot jelképez.

A szokványos spektrogrammon kívül használatos még a MFCCs (Mel-Frequency Cepstral Coefficients) is. Felépítése hasonló a spektogramméval, viszont a frekencia helyett MFC koefficens értéke van az y tengelyen. Ez a Mel skála, amely úgy van megválasztva, hogy a skálán egyelő távolságra lévő hangok az emberi fül számára is hasonló távolságúnak tűnjenek. A frekvenciához képest egy lényeges változást jelent, hiszen az ember számára könnyen hallható kisebb frekvenciákon, például az 500 Hz és 1000 Hz közötti különbség, míg 6500 Hz és 7000 Hz között már kevésbé számottevő az eltérés. Ez utóbbi érték nagyságrendekkel kisebb a frekvencia értéknél így lényegesen befolyásolhatja a neurális háló tanulási folyamatát.

Az előfeldolgozott jelet időegységekre bontjuk, melyek már a neurális háló bemenetét képzik. A kimeneten az egyes időegységekre kapott predikciókból pedig összeállítható a feltételezett szöveg.




**3.1. ábra.** Spectogram.

#### 3.2.2. Neurális hálók

A neurális hálók az emberi idegek működésének mintája alapján modellezett láncolatok. Számos különböző, komplex feladat megoldására előszeretettel alkalmazzák őket. Röviden összefoglalva három fő alkotó részt kell elképzelni. Egyik a bemenet, például egy kép esetén a pixelek, beszédfelismerés esetén az egyes időpillanatokhoz tartozó értékek vektor formában. Spektogram esetén az időpillanathoz tartozó vektor egyes elemei a frekvenciát jelképezik és az elemek értéke pedig a hangerősséget.

A neurális háló közbülső, rejtettnek, nevezett része tetszőleges méreteket ölthet. Az egyes rétegek pontjai mindig az előző réteg pontjaival vannak összekötve úgy nevezett súlyok segítségével. Az újabb rétegek pontjainak értékét az abba befutó súlyok, illetve a súlyok és kiinduló pontjuk szorzatainak az összegével számítjuk. A pontok végső értéke még egy aktivációs függvénynek nevezett kiértékelésen is ekresztül megy mielőtt a következő réteg értékeit kiszámítatnánk vele. Az aktivációs függvények igen eltérőek lehetnek, egy népszerű függvény a ReLU. Ezeket a pontokat neuronoknak szokás nevezni, innen ered a neurálsi háló kifejezés. A háló tanítása során ezen súlyok értékét módosítjuk úgy, hogy a legoptimálisabb, számunkra kedvezőnek vélt eredményt kapjuk.



**3.2. ábra.** A ReLU aktivációs függvény.

Az utolsó réteg a kimeneti réteg, ahol az eredményt kapjuk meg. A kimeneti réteg lehet regresszív, egy előre meg nem határozott, tetszőleges érték, vagy a mi esetünkben klasszifikáció, amikor előre meghatározott címkék (label-ek) valószínűségére vagyunk kíváncsiak. Legyegyszerűbb estben a legvalószínűbb címke kerül kiválasztásra válaszként.

A valószínség kiszámításához a softmax függvényt szokás használni, ami szintén egy aktivációs függvény. A függvény egy vektor bemenetet megkapva normalizálja a vektor egyes értékeit úgy, hogy azok új értékei 0 és 1 közé essenek, miközben az összegük pontosan 1-et adjon. A softmax függvény, ahol x a bemeneti vektort jelöli, míg i és j a vektor egyes elemeinek a sorszámát:

$$softmax(x)_i = \frac{exp(x_i)}{\sum_j exp(x_j)}.$$
 (3.1)

Neurális hálót legyakrabban felügyelten tanítanak, ami azt jelenti, hogy először például egy tanítatlan, véletlenszerűen inicializált, hálóból kiindulva kiértékeljük egy tetszőleges bemenetre a végeredményt. Majd a végeredmény helyességétől függően változtatjuk a súlyok értékét a hálóban: azon súlyokat melyek egy rossz eredmény nagyobb valószínűségéhez járultak hozzá büntetjük, csökkentjük az értéküket, míg azokat melyek egy jó eredmény pozitív értékéhez járultnak hozzá növeljük. Ezt a folyamatot szokás backpropagation-nak nevezni. A büntetés mértéke is létfontosságú, hiszen fontos, hogy ne csak az adott bemenetre tudjon pontos végeredményt adni a háló, hanem általánosan is pontos legyen.

Az egyik legegyszerűbb réteg típus a Dense (sűrű) vagy más néven Fully Connected, ahogy a neve is mutatja a súlyokkal sűrűn vannak összekötve az egyes neuronok. Csak Dense rétegekből álló neurális háló esetén minden neuronba az előző réteg összes neuronja össze van kötve súlyokkal a következő réteg összes neuronjával.


Lényegesen összetettebb a konvolúciós réteg [5], melynél egy a teljes bemenetnél kisebb kernel-t (vagy filter-t) mozgatunk végig a bemeneten és kiértékeljük, majd összevonva egy értékké azokat a számokat, melyek a kernel-en belül vannak. A kernel-t egy megadott értékkel, a stride-al mozgatva kiértékeljük a következő, kernel által lefedett, számokat és így tovább. A konvolúció végezhető egy vagy több dimenziós bemeneten, több kernel-el is, kép esetén például három csatornás képen, ahol a piros kék és zöld értékek külön csatornákon vannak reprezentálva. Külön érdekes, hogy a bement széleit feltöltjük-e nullásokkal, ez az úgy nevezett zero padding. Ennek célja, hogy ugyan akkora legyen a kimenet, mint a padding nélküli bemenet volt. Ezen kívül is szükség lehet padding-re például egy 5x5-ös kép esetén, ha a kernel mérete 3x3 és a stride 3, akkor ki kell tölteni a kép széleit, hogy minden bemeneti értéken legalább egyszer végig menjen a kernel.

A konvolúciós hálok gyakran csökkentik a kapott bemenet méretét. A kimenet méretét a következő képlettel lehet kiszámolni, ahol 'O' a kimenet mérete, 'W' a bemenet mérete, 'P' a padding mérete, 'K' a kernel mérete és 'S' a stride:

$$\mathbf{O} = \frac{\mathbf{W} - \mathbf{K} + 2\mathbf{P}}{\mathbf{S} + (1)}.\tag{3.2}$$

Az E2E-hez használt leggyakoribb neurális háló réteg fajták az rekurrens (RNN) és konvolúciós (CNN) rétegek. Ez utóbbit elterjedten használáják a különböző képfelismerő feladatok terültén is.

A rekurrens rétegek [6] egyik legérdekesebb tulajdonsága, hogy nem csupán a súlyaikat használják a neuronok kiértékeléséhez, így felhasználva a korábban tanultakat, hanem emlékeznek a korábbi bemenetekre, így azok befolyásolhatják az újabb bemenetre adott értékelést. Beszédfelismerés esetén ezt úgy is el lehet képzelni, hogy ha például elhangzik egy magánhangzó, akkor utána nagy valószínűséggel egy mássalhangzót várunk, ennek fényében, sikeres tanítás esetén, a mássalhangzókat részesíti előnyben egy azt megelőző magánhangzó után. Korábbi állapotok tehát hozzájárulnak egy újabb állapot kiértékeléséhez a rekurrens rétegben, ahogy ez a 2. ábrán is látható.



3.3. ábra. A rekurrens réteg "kigörgetve".

Két altípusa a rekurrens hálóknak az LSTM és GRU (Long Short Term Memory, Gated Recurrent Unit). Ezek a típusok hasonló elveken működnek, a különbség a korábbi bemenetek újabb bementekre történő ráhatásának számítási módjában rejlik. Az LSTM [7] fő célja, hogy kijátssza a hagyományos rekurrens hálók egyik legnagyobb problémáját, azt, hogy a régebbi bemenet súlya nincs hasonló fontossággal kezelve, mint a jelenlegi bemenethez közelebbi érték. Természetesen fontos lehet egy mondat végi szót vizsgálva, hogy mi volt a szó a mondat elején, még jobban is, mint a vizsgálandó szót megelőző néhány szó. Az LSTM kapukat használ annak megelőzése céljából, hogy egy korábbi hiba elvesszen, ezáltal kezelhetetlenné téve a hiba értékelését.

A GRU egy LSTM-hez hasonló újabb fejlesztésű réteg. Egyik fő tulajdonsága, hogy kevesebb elemet tartalmaz, így kevesebb paramétert használ, csökkentve a neurális háló komplexitását.

Megemlítendő még a Bi-directional (két irányú) réteg, amely mögött az a gondolat húzódik meg, hogy ne csak a múltbéli bemenetek befolyásolják az adott bemenetünket, hanem a jövőbeliek is. Két rekurrens réteget használ, melyek ellentétes irányban haladnak egymással, így tetszőleges kiértékelésnél használhatóak a korábbi, illetve elkövetkezendő bemenetek eredményei is.

#### 3.2.3. CTC loss számítás

A CTC funkciója a neurális háló tanításához használt loss kiszámítása, illetve a kimeneti mátrix dekódolása, a válasz kiértékelése, mely folyamán átalakítja a kimenetet a megadott címkék valószínűségi szekvenciájára. A címkék lehetnek az egyes karakterek, amik egy adott nyelvben előfordulhatnak. Ez esetben a CTC kiértékeli, hogy melyik betű vagy egyéb karakter hangzott el adott időpillanatban, adott bemenetre [8]. Ereje abban rejlik, hogy nincs szükség a kiértékelésnél a kimeneteket egyenként, karakter szinten összekötni az elvárt szöveggel, elegendő a kimeneti szöveget megadni, azt, amit kapni szeretnék a bementre. Másik fontos előnye, hogy a felismert szöveget nem szükséges külön feldolgozni, mivel átalakítja azt a végleges, feltételezett formára, például feldolgozza azt, egy hosszú hang esetén, mint az 'ú' amikor könnyen lehet, hogy több időpillanaton keresztül is hallatszik az 'ú' betű, de nekünk a végeredményben csak egy darab 'ú' szükséges.

Felmerülhet egy probléma az összevonással, amikor olyan egymást követő betűket vonunk össze, melyek a szóban külön szerepelnek, mint például a 'rabbit' szóban.
Ennek elkerülése végett bevezet a CTC egy üres karaktert, ami nem egyenlő a szóközzel, és ezt olyan időegységekhez helyezi, ahol ismerhető fel betű a megadott szótárból, karaktergyűjteményből. Az ilyen üres karakterrel elválasztott betűket nem
fogja összevonni kiértékeléskor.

Kiértékelés után az ember által feldolgozható kimenet megkapásáig szükség van még dekódolásra. Az egyik legalapvetőbb dekódolási algoritmus a best path dekódolási eljárás. Két dolgot végez: kiszámolja a legvalószínűbb útvonalat a kapott kimeneti időegységeken át, majd eltávolítja az egymást követő azonos karaktereket, melyek közt nem található az üres karakter.

Tervezés

Összefoglalás

# IAT<sub>E</sub>X-eszközök

#### 6.1. A szerkesztéshez használatos eszközök

Ez a sablon TeXstudio 2.8.8 szerkesztővel készült. A TeXstudio egy platformfüggetlen, Windows, Linux és Mac OS alatt is elérhető LATEX-szerkesztőprogram számtalan hasznos szolgáltatással (6.1. ábra). A szoftver ingyenesen letölthető<sup>1</sup>.

A TeXstudio telepítése után érdemes még letölteni a magyar nyelvű helyesírásellenőrző-szótárakat hozzá. A TeXstudio az OpenOffice-hoz használatos formátumot tudja kezelni. A TeXstudio beállításainál a General fülön a Dictionaries résznél tudjuk megadni, hogy melyik szótárat használja.

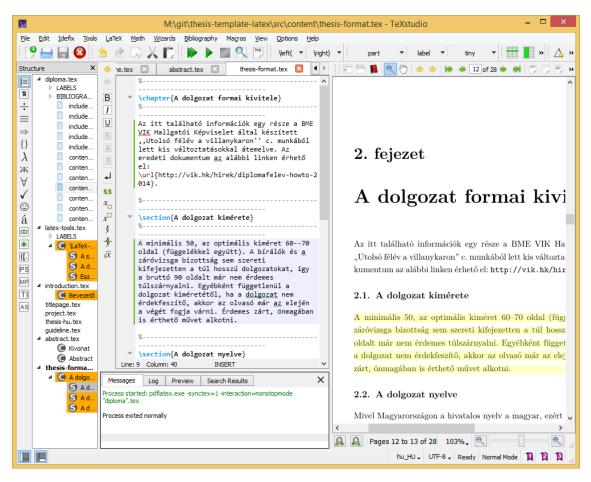
Egy másik használható Windows alapú szerkesztőprogram a LEd<sup>2</sup> (LaTeX Editor), a TeXstudio azonban stabilabb, gyorsabb, és jobban használható.

#### 6.2. A dokumentum lefordítása Windows alatt

A TeXstudio és a LEd kizárólag szerkesztőprogram (bár az utóbbiban DVI-nézegető is van), így a dokumentum fordításához szükséges eszközöket nem tartalmazza. Windows alatt alapvetően két lehetőség közül érdemes választani: MiKTeX (http://miktex.org/) és TeX Live (http://www.tug.org/texlive/) programcsomag. Az utóbbi működik Mac OS X, GNU/Linux alatt és Unix-származékokon is. A MiK-TeX egy alapcsomag telepítése után mindig letölti a használt funkciókhoz szükséges,

<sup>&</sup>lt;sup>1</sup>A TeXstudio hivatalos oldala: http://texstudio.sourceforge.net/

<sup>&</sup>lt;sup>2</sup>A LEd hivatalos oldala: http://www.latexeditor.org/



6.1. ábra. A TeXstudio LATEX-szerkesztő.

de lokálisan hiányzó TEX-csomagokat, míg a TeX Live DVD ISO verzóban férhető hozzá. Ez a dokumentum TeX Live 2008 programcsomag segítségével fordult, amelynek DVD ISO verziója a megadott oldalról letölthető. A sablon lefordításához a disztribúcióban szereplő magyar.ldf fájlt a http://www.math.bme.hu/latex/változatra kell cserélni, vagy az utóbbi változatot be kell másolni a projekt-könyvtárba (ahogy ezt meg is tettük a sablonban) különben anomáliák tapasztalhatók a dokumentumban (pl. az ábra- és táblázat-aláírások formátuma nem a beállított lesz, vagy bizonyos oldalakon megjelenik alapértelmezésben egy fejléc). A TeX Live 2008-at még nem kell külön telepíteni a gépre, elegendő DVD-ről (vagy az ISO fájlból közvetlenül, pl. DaemonTools-szal) használni.

Ha a MiKTeX csomagot használjuk, akkor parancssorból a következő módon tudjuk újrafordítani a teljes dokumentumot:

\$ texify -p thesis.tex

A texify parancs a MiKTex programcsomag miktex/bin alkönyvtárában található. A parancs gondoskodik arról, hogy a szükséges lépéseket (fordítás, hivatkozások generálása stb.) a megfelelő sorrendben elvégezze. A -p kapcsoló hatására PDF-et generál. A fordítást és az ideiglenes fájlok törlését elvégezhetjük a sablonhoz mellékelt manual\_build.bat szkript segítségével is.

A TEX-eszközöket tartalmazó programcsomag binárisainak elérési útját gyakran be kell állítani a szerkesztőprogramban, például TeXstudio esetén legegyszerűbben az Options / Configure TeXstudio... / Commands menüponttal előhívott dialógusablakban tehetjük ezt meg.

A PDF-ETEX használata esetén a generált dokumentum közvetlenül PDFformátumban áll rendelkezésre. Amennyiben a PDF-fájl egy PDF-nézőben (pl. Adobe Acrobat Reader vagy Foxit PDF Reader) meg van nyitva, akkor a fájlleírót a
PDF-néző program tipikusan lefoglalja. Ilyen esetben a dokumentum újrafordítása
hibaüzenettel kilép. Ha bezárjuk és újra megnyitjuk a PDF dokumentumot, akkor
pedig a PDF-nézők többsége az első oldalon nyitja meg a dokumentumot, nem a
legutóbb olvasott oldalon. Ezzel szemben például az egyszerű és ingyenes Sumatra PDF nevű program képes arra, hogy a megnyitott dokumentum megváltozását
detektálja, és frissítse a nézetet az aktuális oldal megtartásával.

#### 6.3. Eszközök Linuxhoz

Linux operációs rendszer alatt is rengeteg szerkesztőprogram van, pl. a KDE alapú Kile jól használható. Ez ingyenesen letölthető, vagy éppenséggel az adott Linux-disztribúció eleve tartalmazza, ahogyan a dokumentum fordításához szükséges csomagokat is. Az Ubuntu Linux disztribúciók alatt például legtöbbször a texlive-\* csomagok telepítésével használhatók a LATEX-eszközök. A jelen sablon fordításához szükséges csomagok (kb. 0,5 GB) az alábbi paranccsal telepíthetők:

Amennyiben egy újabb csomag hozzáadása után hiányzó fájlra utaló hibát kapunk a fordítótól, telepítenünk kell az azt tartalmazó TeX Live csomagot. Ha pl. a bibentry csomagot szeretnénk használni, futtassuk az alábbi parancsot:

```
$ apt-cache search bibentry
texlive-luatex - TeX Live: LuaTeX packages
```

Majd telepítsük fel a megfelelő TeX Live csomagot, jelen esetben a texlive-lualatex-et. (Egy LaTeX csomag több TeX Live csomagban is szerepelhet.)

Ha gyakran szerkesztünk más LATEXdokumentumokat is, kényelmes és biztos megoldás a teljes TeX Live disztribúció telepítése, ez azonban kb. 4 GB helyet igényel.

sudo apt-get install texlive-full

# A dolgozat formai kivitele

Az itt található információk egy része a BME VIK Hallgatói Képviselet által készített "Utolsó félév a villanykaron" c. munkából lett kis változtatásokkal átemelve. Az eredeti dokumentum az alábbi linken érhető el: http://vik.hk/hirek/diplomafelev-howto-2015.

## 7.1. A dolgozat kimérete

Szakdolgozat esetében minimum 30, 45 körüli ajánlott oldalszám lehet az iránymutató. De mindenképp érdemes rákérdezni a konzulensnél is az elvárásokra, mert tanszékenként változóak lehetnek az elvárások.

Mesterképzésen a Diplomatervezés 1 esetében a beszámoló még inkább az Önálló laboratóriumi beszámolókhoz hasonlít, tanszékenként eltérő formai követelményekkel, – egy legalább 30 oldal körüli dolgozat az elvárt – és az elmúlt fél éves munkáról szól. De egyben célszerű, ha ez a végleges diplomaterv alapja is. (A végleges 60-90 oldal körülbelül a hasznos részre nézve)

### 7.2. A dolgozat nyelve

Mivel Magyarországon a hivatalos nyelv a magyar, ezért alapértelmezésben magyarul kell megírni a dolgozatot. Aki külföldi posztgraduális képzésben akar részt venni, nemzetközi szintű tudományos kutatást szeretne végezni, vagy multinacionális cégnél akar elhelyezkedni, annak célszerű angolul megírnia diplomadolgozatát. Mielőtt

a hallgató az angol nyelvű verzió mellett dönt, erősen ajánlott mérlegelni, hogy ez mennyi többletmunkát fog a hallgatónak jelenteni fogalmazás és nyelvhelyesség terén, valamint – nem utolsó sorban – hogy ez mennyi többletmunkát fog jelenteni a konzulens illetve bíráló számára. Egy nehezen olvasható, netalán érthetetlen szöveg teher minden játékos számára.

### 7.3. A dokumentum nyomdatechnikai kivitele

A dolgozatot A4-es fehér lapra nyomtatva, 2,5 centiméteres margóval (+1 cm kötésbeni), 11–12 pontos betűmérettel, talpas betűtípussal és másfeles sorközzel célszerű elkészíteni.

Annak érdekében, hogy a dolgozat külsőleg is igényes munka benyomását keltse, érdemes figyelni az alapvető tipográfiai szabályok betartására [?].

# A IATEX-sablon használata

Ebben a fejezetben röviden, implicit módon bemutatjuk a sablon használatának módját, ami azt jelenti, hogy sablon használata ennek a dokumentumnak a forráskódját tanulmányozva válik teljesen világossá. Amennyiben a szoftver-keretrendszer telepítve van, a sablon alkalmazása és a dolgozat szerkesztése ETEX-ben a sablon segítségével tapasztalataink szerint jóval hatékonyabb, mint egy WYSWYG (What You See is What You Get) típusú szövegszerkesztő esetén (pl. Microsoft Word, OpenOffice).

#### 8.1. Címkék és hivatkozások

A LaTeX dokumentumban címkéket (\label) rendelhetünk ábrákhoz, táblázatokhoz, fejezetekhez, listákhoz, képletekhez stb. Ezekre a dokumentum bármely részében hivatkozhatunk, a hivatkozások automatikusan feloldásra kerülnek.

A sablonban makrókat definiáltunk a hivatkozások megkönnyítéséhez. Ennek megfelelően minden ábra (figure) címkéje fig: kulcsszóval kezdődik, míg minden táblázat (table), képlet (equation), fejezet (section) és lista (listing) rendre a tab:, eq:, sec: és lst: kulcsszóval kezdődik, és a kulcsszavak után tetszőlegesen választott címke használható. Ha ezt a konvenciót betartjuk, akkor az előbbi objektumok számára rendre a \figref, \tabref, \eqref, \sectref és \listref makrókkal hivatkozhatunk. A makrók paramétere a címke, amelyre hivatkozunk (a kulcsszó nélkül). Az összes említett hivatkozástípus, beleértve az \url kulcsszóval beveze-

tett web-hivatkozásokat is a hyperref¹ csomagnak köszönhetően aktívak a legtöbb PDF-nézegetőben, rájuk kattintva a dokumentum megfelelő oldalára ugrik a PDF-néző vagy a megfelelő linket megnyitja az alapértelmezett böngészővel. A hyperref csomag a kimeneti PDF-dokumentumba könyvjelzőket is készít a tartalomjegyzék-ből. Ez egy szintén aktív tartalomjegyzék, amelynek elemeire kattintva a nézegető behozza a kiválasztott fejezetet.

### 8.2. Ábrák és táblázatok

Használjunk vektorgrafikus ábrákat, ha van rá módunk. PDFLaTeX használata esetén PDF formátumú ábrákat lehet beilleszteni könnyen, az EPS (PostScript) vektorgrafikus képformátum beillesztését a PDFLaTeX közvetlenül nem támogatja (de lehet konvertálni, lásd később). Ha vektorgrafikus formában nem áll rendelkezésünkre az ábra, akkor a veszteségmentes PNG, valamint a veszteséges JPEG formátumban érdemes elmenteni. Figyeljünk arra, hogy ilyenkor a képek felbontása elég nagy legyen ahhoz, hogy nyomtatásban is megfelelő minőséget nyújtson (legalább 300 dpi javasolt). A dokumentumban felhasznált képfájlokat a dokumentum forrása mellett érdemes tartani, archiválni, mivel ezek hiányában a dokumentum nem fordul újra. Ha lehet, a vektorgrafikus képeket vektorgrafikus formátumban is érdemes elmenteni az újrafelhasználhatóság (az átszerkeszthetőség) érdekében.

Kapcsolási rajzok legtöbbször kimásolhatók egy vektorgrafikus programba (pl. CorelDraw) és onnan nagyobb felbontással raszterizálva kimenthatők PNG formátumban. Ugyanakkor kiváló ábrák készíthetők Microsoft Visio vagy hasonló program használatával is: Visio-ból az ábrák közvetlenül PDF-be is menthetők.

Lehetőségeink Matlab ábrák esetén:

- Képernyőlopás (*screenshot*) is elfogadható minőségű lehet a dokumentumban, de általában jobb felbontást is el lehet érni más módszerrel.
- A Matlab ábrát a File/Save As opcióval lementhetjük PNG formátumban (ugyanaz itt is érvényes, mint korábban, ezért nem javasoljuk).

<sup>&</sup>lt;sup>1</sup>Segítségével a dokumentumban megjelenő hivatkozások nem csak dinamikussá válnak, de színezhetők is, bővebbet erről a csomag dokumentációjában találunk. Ez egyúttal egy példa lábjegyzet írására.

- A Matlab ábrát az Edit/Copy figure opcióval kimásolhatjuk egy vektorgrafikus programba is és onnan nagyobb felbontással raszterizálva kimenthatjük
  PNG formátumban (nem javasolt).
- Javasolt megoldás: az ábrát a File/Save As opcióval EPS vektorgrafikus formátumban elmentjük, PDF-be konvertálva beillesztjük a dolgozatba.

Az EPS kép az epstopdf programmal<sup>2</sup> konvertálható PDF formátumba. Célszerű egy batch-fájlt készíteni az összes EPS ábra lefordítására az alábbi módon (ez Windows alatt működik).

```
@echo off
for %%j in (*.eps) do (
   echo converting file "%%j"
   epstopdf "%%j"
)
echo done .
```


Egy ilyen parancsfájlt (convert.cmd) elhelyeztük a sablon figures\eps könyvtárába, így a felhasználónak csak annyi a dolga, hogy a figures\eps könyvtárba kimenti az EPS formátumú vektorgrafikus képet, majd lefuttatja a convert.cmd parancsfájlt, ami PDF-be konvertálja az EPS fájlt.


Ezek után a PDF-ábrát ugyanúgy lehet a dokumentumba beilleszteni, mint a PNG-t vagy a JPEG-et. A megoldás előnye, hogy a lefordított dokumentumban is vektorgrafikusan tárolódik az ábra, így a mérete jóval kisebb, mintha raszterizáltuk volna beillesztés előtt. Ez a módszer minden – az EPS formátumot ismerő – vektorgrafikus program (pl. CorelDraw) esetén is használható.


A képek beillesztésére a 6. fejezetben mutattunk be példát (6.1. ábra). Az előző mondatban egyúttal az automatikusan feloldódó ábrahivatkozásra is láthatunk példát. Több képfájlt is beilleszthetünk egyetlen ábrába. Az egyes képek közötti horizontális és vertikális margót metrikusan szabályozhatjuk (8.1. ábra). Az ábrák elhelyezését számtalan tipográfiai szabály egyidejű teljesítésével a fordító maga végzi, a dokumentum írója csak preferenciáit jelezheti a fordító felé (olykor ez bosszúságot is okozhat, ilyenkor pl. a kép méretével lehet játszani).

A táblázatok használatára a 8.1 táblázat mutat példát. A táblázatok formázásához hasznos tanácsokat találunk a booktabs csomag dokumentációjában.

<sup>&</sup>lt;sup>2</sup>a korábban említett IAT<sub>F</sub>X-disztribúciókban megtalálható









**8.1. ábra.** Több képfájl beillesztése esetén térközöket is érdemes használni.

### 8.3. Felsorolások és listák

Számozatlan felsorolásra mutat példát a jelenlegi bekezdés:

- első bajusz: ide lehetne írni az első elem kifejését,
- második bajusz: ide lehetne írni a második elem kifejését,
- ez meg egy szakáll: ide lehetne írni a harmadik elem kifejését.

Számozott felsorolást is készíthetünk az alábbi módon:

- 1. *első bajusz:* ide lehetne írni az első elem kifejését, és ez a kifejtés így néz ki, ha több sorosra sikeredik,
- 2. második bajusz: ide lehetne írni a második elem kifejését,
- 3. ez meg egy szakáll: ide lehetne írni a harmadik elem kifejését.

Órajel	Frekvencia	Cél pin
CLKA	$100~\mathrm{MHz}$	FPGA CLK0
CLKB	$48~\mathrm{MHz}$	FPGA CLK1
CLKC	$20 \mathrm{\ MHz}$	Processzor
CLKD	$25~\mathrm{MHz}$	Ethernet chip
CLKE	72  MHz	FPGA CLK2
XBUF	$20~\mathrm{MHz}$	FPGA CLK3

**8.1.** táblázat. Az órajel-generátor chip órajel-kimenetei.

A felsorolásokban sorok végén vessző, az utolsó sor végén pedig pont a szokásos írásjel. Ez alól kivételt képezhet, ha az egyes elemek több teljes mondatot tartalmaznak.

Listákban a dolgozat szövegétől elkülönítendő kódrészleteket, programsorokat, pszeudo-kódokat jeleníthetünk meg (8.1. kódrészlet).

```
\begin{enumerate}
\item \emph{első bajusz:} ide lehetne írni az első elem kifejését,
és ez a kifejtés így néz ki, ha több sorosra sikeredik,
\item \emph{második bajusz:} ide lehetne írni a második elem kifejését,
\item \emph{ez meg egy szakáll:} ide lehetne írni a harmadik elem kifejését.
\end{enumerate}
```

8.1. lista. A fenti számozott felsorolás LATEX-forráskódja

A lista keretét, háttérszínét, egész stílusát megválaszthatjuk. Ráadásul különféle programnyelveket és a nyelveken belül kulcsszavakat is definiálhatunk, ha szükséges. Erről bővebbet a listings csomag hivatalos leírásában találhatunk.

#### 8.4. Képletek

Ha egy formula nem túlságosan hosszú, és nem akarjuk hivatkozni a szövegből, mint például a  $e^{i\pi}+1=0$  képlet, szövegközi képletként szokás leírni. Csak, hogy másik példát is lássunk, az  $U_i=-d\Phi/dt$  Faraday-törvény a rot  $E=-\frac{dB}{dt}$  differenciális alakban adott Maxwell-egyenlet felületre vett integráljából vezethető le. Látható, hogy a IATEX-fordító a sorközöket betartja, így a szöveg szedése esztétikus marad szövegközi képletek használata esetén is.

Képletek esetén az általános konvenció, hogy a kisbetűk skalárt, a kis félkövér betűk ( $\mathbf{v}$ ) oszlopvektort – és ennek megfelelően  $\mathbf{v}^T$  sorvektort – a kapitális félkövér betűk ( $\mathbf{V}$ ) mátrixot jelölnek. Ha ettől el szeretnénk térni, akkor az alkalmazni kívánt jelölésmódot célszerű külön alfejezetben definiálni. Ennek megfelelően, amennyiben

 $\mathbf{y}$  jelöli a mérések vektorát,  $\vartheta$  a paraméterek vektorát és  $\hat{\mathbf{y}} = \mathbf{X}\vartheta$  a paraméterekben lineáris modellt, akkor a *Least-Squares* értelemben optimális paraméterbecslő  $\hat{\vartheta}_{LS} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$  lesz.

Emellett kiemelt, sorszámozott képleteket is megadhatunk, ennél az equation és a eqnarray környezetek helyett a korszerűbb align környezet alkalmazását javasoljuk (több okból, különféle problémák elkerülése végett, amelyekre most nem térünk ki). Tehát

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u},\tag{8.1}$$

$$\mathbf{y} = \mathbf{C}\mathbf{x},\tag{8.2}$$

ahol  $\mathbf{x}$  az állapotvektor,  $\mathbf{y}$  a mérések vektora és  $\mathbf{A}$ ,  $\mathbf{B}$  és  $\mathbf{C}$  a rendszert leíró paramétermátrixok. Figyeljük meg, hogy a két egyenletben az egyenlőségjelek egymáshoz igazítva jelennek meg, mivel a mindkettőt az & karakter előzi meg a kódban. Lehetőség van számozatlan kiemelt képlet használatára is, például

$$\dot{\mathbf{x}} = \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u},$$

$$\mathbf{y} = \mathbf{C}\mathbf{x}.$$

Mátrixok felírására az  $\mathbf{A}\mathbf{x}=\mathbf{b}$  inhomogén lineáris egyenlet részletes kifejtésével mutatunk példát:

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix}.$$
(8.3)

A \frac utasítás hatékonyságát egy általános másodfokú tag átviteli függvényén keresztül mutatjuk be, azaz

$$W(s) = \frac{A}{1 + 2T\xi s + s^2 T^2}. (8.4)$$

A matematikai mód minden szimbólumának és képességének a bemutatására természetesen itt nincs lehetőség, de gyors referenciaként hatékonyan használhatók a következő linkek:

```
http://www.artofproblemsolving.com/LaTeX/AoPS_L_GuideSym.php,
http://www.ctan.org/tex-archive/info/symbols/comprehensive/
symbols-a4.pdf,
ftp://ftp.ams.org/pub/tex/doc/amsmath/short-math-guide.pdf.
Ez pedig itt egy magyarázat, hogy miért érdemes align környezetet használni:
http://texblog.net/latex-archive/maths/eqnarray-align-environment/.
```

#### 8.5. Irodalmi hivatkozások

Egy LATEX dokumentumban az irodalmi hivatkozások definíciójának két módja van. Az egyik a **\thebibliograhy** környezet használata a dokumentum végén, az **\end{document}** lezárás előtt.

```
\begin{thebibliography}{9}
\bibitem{Lamport94} Leslie Lamport, \emph{\LaTeX: A Document Preparation System}.
Addison Wesley, Massachusetts, 2nd Edition, 1994.
\end{thebibliography}
```

Ezek után a dokumentumban a \cite{Lamport94} utasítással hivatkozhatunk a forrásra. A fenti megadás viszonylag kötetlen, a szerző maga formázza az irodalomjegyzéket (ami gyakran inkonzisztens eredményhez vezet).

Egy sokkal professzionálisabb módszer a BiBTEX használata, ezért ez a sablon is ezt támogatja. Ebben az esetben egy külön szöveges adatbázisban definiáljuk a forrásmunkákat, és egy külön stílusfájl határozza meg az irodalomjegyzék kinézetét. Ez, összhangban azzal, hogy külön formátumkonvenció határozza meg a folyóirat-, a könyv-, a konferenciacikk- stb. hivatkozások kinézetét az irodalomjegyzékben (a sablon használata esetén ezzel nem is kell foglalkoznia a hallgatónak, de az eredményt célszerű ellenőrizni). felhasznált hivatkozások adatbázisa egy .bib kiterjesztésű szöveges fájl, amelynek szerkezetét a A 8.2 kódrészlet demonstrálja. A forrásmunkák bevitelekor a sor végi vesszők külön figyelmet igényelnek, mert hiányuk a BiBTEX-fordító hibaüzenetét eredményezi. A forrásmunkákat típus szerinti kulcsszó vezeti be

(@book könyv, @inproceedings konferenciakiadványban megjelent cikk, @article folyóiratban megjelent cikk, @techreport valamelyik egyetem gondozásában megjelent műszaki tanulmány, @manual műszaki dokumentáció esetén stb.). Nemcsak a megjelenés stílusa, de a kötelezően megadandó mezők is típusról-típusra változnak. Egy jól használható referencia a http://en.wikipedia.org/wiki/BibTeX oldalon található.

```
@book{Wettl04,
          = {Ferenc Wettl and Gyula Mayer and Péter Szabó},
 publisher = {Panem Könyvkiadó},
 title
           = {\LaTeX~kézikönyv},
           = {2004},
 year
@article{Candy86,
 author
              = {James C. Candy},
 journaltitle = {{IEEE} Trans.\ on Communications},
 note
              = {\doi{10.1109/TCOM.1986.1096432}},
              = {1},
 number
              = \{72--76\},
 pages
 title
              = {Decimation for Sigma Delta Modulation},
 volume
              = \{34\}.
 year
               = \{1986\},
@inproceedings{Lee87,
          = {Wai L. Lee and Charles G. Sodini},
 booktitle = {Proc.\ of the IEEE International Symposium on Circuits and Systems},
 location = {Philadelphia, PA, USA},
          = \{05~4--7\},
 month
 pages
           = \{459--462\},
           = {A Topology for Higher Order Interpolative Coders},
           = \{2\},
           = \{1987\},
 year
@thesis{KissPhD,
           = {Peter Kiss},
 institution = {Technical University of Timi\c{s}oara, Romania},
 month
             = {Adaptive Digital Compensation of Analog Circuit Imperfections for Cascaded Delta-
 title
    Sigma Analog-to-Digital Converters},
             = {phdthesis},
 type
             = \{2000\},
 year
}
```

```
@manual{Schreier00.
               = {Richard Schreier},
  author
 month
               = \{01\},
               = {\url{http://www.mathworks.com/matlabcentral/fileexchange/}},
 organization = {Oregon State University},
               = {The Delta-Sigma Toolbox v5.2},
  title
               = \{2000\},
 year
@misc{DipPortal,
  author
               = {{Budapesti űMszaki és Gazdaságtudományi Egyetem Villamosmérnöki és Informatikai
    Kar}}.
 howpublished = {\url{http://diplomaterv.vik.bme.hu/}},
  title
               = {Diplomaterv portál (2011. február 26.)},
}
@incollection{Mkrtychev:1997,
  author
           = {Mkrtychev, Alexey},
 booktitle = {Logical Foundations of Computer Science},
            = \{10.1007/3-540-63045-7_27\},
            = {Adian, Sergei and Nerode, Anil},
            = \{978-3-540-63045-6\},
  isbn
            = \{266-275\},
 pages
 publisher = {Springer Berlin Heidelberg},
           = {Lecture Notes in Computer Science},
  series
 title
           = {Models for the logic of proofs},
            = {http://dx.doi.org/10.1007/3-540-63045-7_27},
  url
            = \{1234\},
  volume
 year
            = {1997}.
```

#### 8.2. lista. Példa szöveges irodalomjegyzék-adatbázisra BibT<sub>F</sub>X használata esetén.

A stílusfájl egy .sty kiterjesztésű fájl, de ezzel lényegében nem kell foglalkozni, mert vannak beépített stílusok, amelyek jól használhatók. Ez a sablon a BiBTEX-et használja, a hozzá tartozó adatbázisfájl a mybib.bib fájl. Megfigyelhető, hogy az irodalomjegyzéket a dokumentum végére (a \end{document} utasítás elé) beillesztett \bibliography{mybib} utasítással hozhatjuk létre, a stílusát pedig ugyanitt a \bibliographystyle{plain} utasítással adhatjuk meg. Ebben az esetben a plain előre definiált stílust használjuk (a sablonban is ezt állítottuk be). A plain stíluson kívül természetesen számtalan más előre definiált stílus is létezik. Mivel a .bib adatbázisban ezeket megadtuk, a BiBTEX-fordító is meg tudja különböztetni a szerzőt

a címtől és a kiadótól, és ez alapján automatikusan generálódik az irodalomjegyzék a stílusfájl által meghatározott stílusban.

Az egyes forrásmunkákra a szövegből továbbra is a \cite paranccsal tudunk hivatkozni, így a 8.2. kódrészlet esetén a hivatkozások rendre \cite{Wett104}, \cite{Candy86}, \cite{Lee87}, \cite{KissPhD}, \cite{Schreirer00}, \cite{Mkrtychev:1997} és \cite{DipPortal}. Az egyes forrásmunkák sorszáma az irodalomjegyzék bővítésekor változhat. Amennyiben az aktuális számhoz illeszkedő névelőt szeretnénk használni, használjuk az \acite{} parancsot.

Az irodalomjegyzékben alapértelmezésben csak azok a forrásmunkák jelennek meg, amelyekre található hivatkozás a szövegben, és ez így alapvetően helyes is, hiszen olyan forrásmunkákat nem illik az irodalomjegyzékbe írni, amelyekre nincs hivatkozás.

Mivel a fordítási folyamat során több lépésben oldódnak fel a szimbólumok, ezért gyakran többször is le kell fordítani a dokumentumot. Ilyenkor ez első 1-2 fordítás esetleg szimbólum-feloldásra vonatkozó figyelmeztető üzenettel zárul. Ha hiba-üzenettel zárul bármelyik fordítás, akkor nincs értelme megismételni, hanem a hibát kell megkeresni. A .bib fájl megváltoztatáskor sokszor nincs hatása a változtatásnak azonnal, mivel nem mindig fut újra a BibTeX fordító. Ezért célszerű a változtatás után azt manuálisan is lefuttatni (TeXstudio esetén Tools/Bibliography).

Hogy a szövegbe ágyazott hivatkozások kinézetét demonstráljuk, itt most sorban meghivatkozzuk a [?], [?], [?], [?], [?] és a [?]<sup>3</sup> forrásmunkát, valamint a [?] weboldalt.

Megjegyzendő, hogy az ékezetes magyar betűket is tartalmazó .bib fájl az inputenc csomaggal betöltött latin2 betűkészlet miatt fordítható. Ugyanez a .bib fájl hibaüzenettel fordul egy olyan dokumentumban, ami nem tartalmazza a \usepackage[latin2]{inputenc} sort. Speciális igény esetén az irodalmi adatbázis általánosabb érvényűvé tehető, ha az ékezetes betűket speciális latex karakterekkel helyettesítjük a .bib fájlban, pl. á helyett \'{a}-t vagy ő helyett \H{o}-t írunk.

<sup>&</sup>lt;sup>3</sup>Informatikai témában gyakran hivatkozunk cikkeket a Springer LNCS valamely kötetéből, ez a hivatkozás erre mutat egy helyes példát.

Irodalomhivatkozásokat célszerű először olyan szolgáltatásokban keresni, ahol jó minőségű bejegyzések találhatók (pl. ACM Digital Library, DBLP, IEEE Xplore, SpringerLink) és csak ezek után használni kevésbé válogatott forrásokat (pl. Google Scholar). A jó minőségű bejegyzéseket is érdemes megfelelően tisztítani. A sablon angol nyelvű változatában használt plainnat beállítás egyik sajátossága, hogy a cikkhez generált hivatkozás a cikk DOI-ját és URL-jét is tartalmazza, ami gyakran duplikátumhoz vezet – érdemes tehát a DOI-kat tartalmazó URL mezőket törölni.

#### 8.6. A dolgozat szerkezete és a forrásfájlok

A diplomatervsablonban a TeX fájlok két alkönyvtárban helyezkednek el. Az include könyvtárban azok szerepelnek, amiket tipikusan nem kell szerkesztenünk, ezek a sablon részei (pl. címoldal). A content alkönyvtárban pedig a saját munkánkat helyezhetjük el. Itt érdemes az egyes fejezeteket külön TEX állományokba rakni.

A diplomatervsablon (a kari irányelvek szerint) az alábbi fő fejezetekből áll:

- 1. 1 oldalas *tájékoztató* a szakdolgozat/diplomaterv szerkezetéről (include/guideline.tex), ami a végső dolgozatból törlendő,
- 2. feladatkiírás (include/project.tex), a dolgozat nyomtatott verzójában ennek a helyére kerül a tanszék által kiadott, a tanszékvezető által aláírt feladatkiírás, a dolgozat elektronikus verziójába pedig a feladatkiírás egyáltalán ne kerüljön bele, azt külön tölti fel a tanszék a diplomaterv-honlapra,
- 3. címoldal (include/titlepage.tex),
- 4. tartalomjegyzék (thesis.tex),
- a diplomatervező nyilatkozata az önálló munkáról (include/declaration.tex),

<sup>4</sup>https://dl.acm.org/

<sup>&</sup>lt;sup>5</sup>http://dblp.uni-trier.de/

<sup>6</sup>http://ieeexplore.ieee.org/

<sup>7</sup>https://link.springer.com/

<sup>8</sup>http://scholar.google.com/

 $<sup>^9 \</sup>mathtt{https://github.com/FTSRG/cheat-sheets/wiki/BibTeX-Fixing-entries-from-common-sources}$ 

- 6. 1-2 oldalas tartalmi *összefoglaló* magyarul és angolul, illetve elkészíthető még további nyelveken is (content/abstract.tex),
- 7. bevezetés: a feladat értelmezése, a tervezés célja, a feladat indokoltsága, a diplomaterv felépítésének rövid összefoglalása (content/introduction.tex),
- 8. sorszámmal ellátott fejezetek: a feladatkiírás pontosítása és részletes elemzése, előzmények (irodalomkutatás, hasonló alkotások), az ezekből levonható következtetések, a tervezés részletes leírása, a döntési lehetőségek értékelése és a választott megoldások indoklása, a megtervezett műszaki alkotás értékelése, kritikai elemzése, továbbfejlesztési lehetőségek,
- 9. esetleges köszönetnyilvánítások (content/acknowledgement.tex),
- részletes és pontos irodalomjegyzék (ez a sablon esetében automatikusan generálódik a thesis.tex fájlban elhelyezett \bibliography utasítás hatására, a 8.5. szakaszban leírtak szerint),
- 11. függelékek (content/appendices.tex).

A sablonban a fejezetek a thesis.tex fájlba vannak beillesztve \include utasítások segítségével. Lehetőség van arra, hogy csak az éppen szerkesztés alatt álló.tex fájlt fordítsuk le, ezzel lerövidítve a fordítási folyamatot. Ezt a lehetőséget az alábbi kódrészlet biztosítja a thesis.tex fájlban.

```
\includeonly{
  guideline,%
  project,%
  titlepage,%
  declaration,%
  abstract,%
  introduction,%
  chapter1,%
  chapter2,%
  chapter3,%
  acknowledgement,%
  appendices,%
}
```

Ha az alábbi kódrészletben az egyes sorokat a % szimbólummal kikommentezzük, akkor a megfelelő .tex fájl nem fordul le. Az oldalszámok és a tartalomjegyék természetesen csak akkor billennek helyre, ha a teljes dokumentumot lefordítjuk.

## 8.7. Alapadatok megadása

A diplomaterv alapadatait (cím, szerző, konzulens, konzulens titulusa) a thesis.tex fájlban lehet megadni.

## 8.8. Új fejezet írása

A főfejezetek külön content könyvtárban foglalnak helyet. A sablonhoz 3 fejezet készült. További főfejezeteket úgy hozhatunk létre, ha új TEX fájlt készítünk a fejezet számára, és a thesis.tex fájlban, a \include és \includeonly utasítások argumentumába felvesszük az új .tex fájl nevét.

### 8.9. Definíciók, tételek, példák

Definíció 1 (Fluxuskondenzátor térerőssége). Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat.

**Példa 1.** Példa egy példára. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

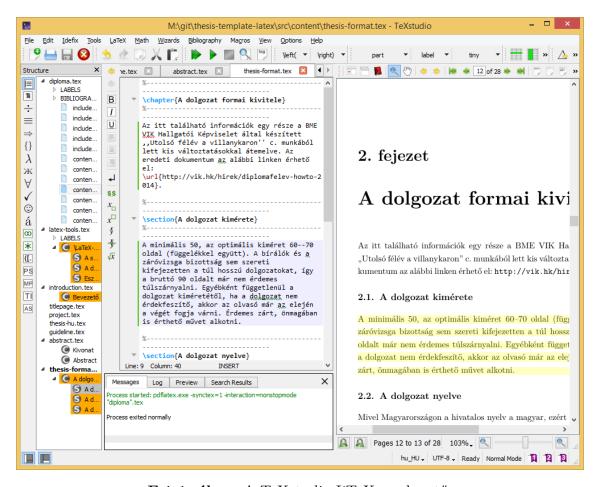
**Tétel 1 (Kovács tétele).** Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

# Köszönetnyilvánítás

Ez nem kötelező, akár törölhető is. Ha a szerző szükségét érzi, itt lehet köszönetet nyilvánítani azoknak, akik hozzájárultak munkájukkal ahhoz, hogy a hallgató a szakdolgozatban vagy diplomamunkában leírt feladatokat sikeresen elvégezze. A konzulensnek való köszönetnyilvánítás sem kötelező, a konzulensnek hivatalosan is dolga, hogy a hallgatót konzultálja.

## Függelék

#### F.1. A TeXstudio felülete



F.1.1. ábra. A TeXstudio LaTeX-szerkesztő.

# F.2. Válasz az "Élet, a világmindenség, meg minden" kérdésére

A Pitagorasz-tételből levezetve

$$c^2 = a^2 + b^2 = 42. (F.2.1)$$

A Faraday-indukciós törvényből levezetve

$$\operatorname{rot} E = -\frac{dB}{dt} \longrightarrow U_i = \oint_{\mathbf{L}} \mathbf{Edl} = -\frac{d}{dt} \int_{A} \mathbf{Bda} = 42.$$
 (F.2.2)